



**CENTRO UNIVERSITÁRIO DE BRASÍLIA - CEUB
CIÊNCIA DA COMPUTAÇÃO**

LUCAS GONÇALVES BALDUINO - 22409139

FRANCISCO BARBOSA RIBEIRO - 22408832

ARTUR FEITOZA DE LIMA RODRIGUES - 22401202

VINICIUS KENJI MIZUNO INOUE - 22308671

ALICE RODRIGUES SOARES - 22400343

INTELIGÊNCIA ARTIFICIAL- PROJETO FINAL

BRASÍLIA

2026

1. APRENDIZAGEM PROFUNDA

O Aprendizado Profundo é uma subdivisão de Aprendizado de Máquina, se inspira na estrutura do cérebro humano utilizando redes neurais para o treinamento e inferência do modelo. As redes neurais são compostas por multicamadas de nodos interconectados que realizam operações matemáticas para extrair padrões complexos a partir de grandes volumes de dados.

2. CNN (Redes Neurais Convolucionais)

As Redes Neurais Convolucionais representam uma arquitetura projetada especificamente para o processamento de dados dispostos em formato de grade estruturada, como imagens digitais e matrizes de vídeo. O principal elemento das CNNs consiste em mimetizar o sistema visual humano para capturar de maneira eficiente relações espaciais e de vizinhança entre os pixels.

O fluxo de processamento padrão de uma CNN é composto por uma sequência lógica de camadas:

- **Camada Convolutiva:** Aplica uma série de filtros matemáticos (kernels) reutilizáveis que deslizam sobre a imagem para gerar mapas de características (feature maps), identificando padrões elementares como bordas, texturas, linhas e formas.
- **Camada de Ativação:** Geralmente composta por funções que adicionam não linearidade à rede.
- **Camada de Pooling:** Executa a compressão e simplificação desses mapas.
- **Camada Totalmente Conectada:** Posicionada ao final da rede, unifica os vetores de características para realizar a tarefa de classificação final.

2.1 Max Pooling

O Max Pooling é uma operação de subamostragem crucial para a viabilidade computacional das CNNs. A técnica opera deslizando uma janela bidimensional com dimensões fixas (comumente uma matriz de 2 x 2 pixels associada a um deslocamento de 2) e extraíndo exclusivamente o valor máximo contido naquela partição.

O emprego do Max Pooling gera três vantagens imediatas para a rede:

- **Redução da Dimensionalidade:** Reduz o tamanho espacial do mapa de características, poupando consideravelmente memória RAM e tempo de processamento nas etapas seguintes.
- **Mitigação do Overfitting:** Ao descartar variações menores de intensidade e focar no ponto mais saliente, impede que o modelo decore ruídos irrelevantes da base de treinamento.
- **Invariância Translacional:** Permite que o modelo reconheça um determinado padrão ou objeto mesmo se ele estiver ligeiramente deslocado, rotacionado ou alterado em escala na imagem.

3. RNN

Enquanto as redes do tipo feedforward assumem que todas as entradas e saídas são independentes entre si, as Redes Neurais Recorrentes (RNNs) surgem para trabalhar com o fator tempo e ordenação, sendo ideais para a modelagem de dados sequenciais e séries temporais.

As RNNs contam com loops estruturais em sua arquitetura de nós. Essa retroalimentação permite o tráfego contínuo de um "estado oculto", que atua como uma memória interna de curto prazo. Desse modo, o processamento de um elemento corrente na sequência leva em consideração os elementos que o antecederam, fornecendo contexto e encadeamento histórico ao modelo.

4. LONG SHORT-TERM MEMORY (LSTM)

Apesar do avanço conceitual trazido pelas RNNs, redes recorrentes tradicionais falham ao tentar correlacionar dados muito distantes na mesma sequência devido ao problema matemático do desvanecimento do gradiente. Nesse cenário, as taxas de erro acumuladas fazem a rede zerar a retenção de contexto antigo.

Para solucionar essa barreira, foi desenvolvida a arquitetura Long Short-Term Memory (LSTM). As LSTMs introduzem o conceito de célula de memória e utilizam estruturas reguladoras chamadas portões para controlar o fluxo de dados:

- **Forget Gate (Portão de Esquecimento):** Analisa a relevância do contexto histórico recebido e determina matematicamente quais informações antigas devem ser descartadas.
- **Input Gate (Portão de Entrada):** Seleciona quais novos dados vindos do processamento atual possuem relevância real para atualizar o estado interno da célula.
- **Output Gate (Portão de Saída):** Filtra e define o que será efetivamente repassado para o próximo passo oculto da rede neural.

5. MECANISMO DE ATENÇÃO (ATTENTION)

O Mecanismo de Atenção representou uma das maiores viradas de paradigma na história recente do aprendizado profundo. Apesar dos avanços dos modelos tradicionais, os RNNs e LSTMs sofriam com um gargalo de desempenho: comprimiam blocos textuais extensos em um único vetor estático de tamanho fixo, gerando severa perda de dados informativos.

O mecanismo de atenção quebra essa limitação, permitindo que a rede neural foque dinamicamente em partes específicas e isoladas da entrada na hora de prever ou gerar uma saída, estabelecendo pontes matemáticas de relevância entre palavras ou elementos distantes na sequência.

6. FUNÇÕES DE ATIVAÇÃO

As funções de ativação consistem em operações matemáticas aplicadas diretamente sobre o resultado da soma ponderada dos pesos e vieses de um neurônio artificial. Sem a presença dessas funções, uma rede neural agiria puramente como uma equação de regressão linear massiva, tornando-se incapaz de computar ou mapear comportamentos e dados complexos, de alta dimensionalidade e não lineares.

Dentre as funções destacam-se:

- **ReLU (Rectified Linear Unit):** Definida pela fórmula $f(x) = \max(0, x)$. Transforma todas as saídas negativas em zero e mantém intactas as positivas. É a mais utilizada em camadas ocultas de redes profundas por mitigar o desvanecimento de gradientes e agilizar o treinamento.
- **Sigmoide:** Comprime os outputs para uma escala decimal estrita entre 0 e 1, simulando probabilidade, o que a torna a escolha ideal para camadas finais de classificação binária.
- **Tanh (Tangente Hiperbólica):** Mapeia os dados em um espectro entre -1 e 1, centralizando as respostas estruturais próximas a zero.

7. SOFTMAX

Uma generalização da função sigmoide aplicada à camada de saída de redes de classificação multiclasse. Ela normaliza a saída da rede para que todos os valores fiquem entre 0 e 1 e a sua soma total seja exatamente 1, funcionando como uma distribuição de probabilidade das classes.

8. CAMADAS OCULTAS

São as camadas intermediárias posicionadas entre a entrada (input) e a saída (output). Cada neurônio nestas camadas recebe entradas das camadas anteriores, aplica um peso, adiciona um viés (*bias*), passa por uma função de ativação e transmite o resultado para a próxima camada. É nelas que a rede aprende a hierarquia dos dados: camadas iniciais identificam padrões simples (bordas/traços), enquanto as profundas reconhecem conceitos complexos (objetos/contextos).

9. GRADIENTE DESCENDENTE

É o algoritmo de otimização central. Ele ajusta iterativamente os pesos da rede para minimizar a função de perda (a diferença entre a previsão da rede e o valor real). O gradiente aponta a direção do aumento do erro; o algoritmo, então, move-se na direção oposta (descida) para encontrar o ponto de erro mínimo.

10. EXEMPLOS DE APLICAÇÕES DE APRENDIZAGEM PROFUNDA

O aprendizado profundo apresenta vasta aplicabilidade prática em cenários contemporâneos:

- **Sistemas de Reconhecimento Facial:** Utilizado por agências de segurança e dispositivos móveis para mapeamento biométrico preciso de características faciais humanas a partir de redes convolucionais.
- **Navegação e Veículos Autônomos:** Aplicação integrada de CNNs e modelos de tomada de decisão em tempo real para permitir que carros inteligentes identifiquem pedestres, ciclistas, faixas de sinalização e obstáculos urbanos.
- **Processamento de Linguagem Natural (PLN):** Implementado no desenvolvimento de tradutores automatizados contextuais, sistemas de geração de legenda automotiva e assistentes inteligentes de voz através de mecanismos de atenção.

- **Medicina e Diagnóstico por Imagem:** Treinamento de redes neurais profundas com milhões de exames clínicos para a detecção automatizada de tumores malignos microscópicos, anomalias pulmonares e patologias oculares com precisão equiparável à de médicos radiologistas.
- **Detecção de Fraudes Financeiras:** Redes recorrentes (LSTMs) que analisam continuamente o fluxo sequencial de transações bancárias de clientes ao redor do mundo para detectar instantaneamente comportamentos atípicos e transações fraudulentas.
- **Previsão do Clima e Séries Temporais:** Modelagem preditiva do comportamento meteorológico global e de oscilações do mercado de ações através do cruzamento de séries temporais históricas complexas.

ARQUITETURAS EM APRENDIZAGEM PROFUNDA

Arquitetura	Estrutura das Camadas	Aplicação
ResNet	Utiliza "conexões residuais" (<i>skip connections</i>) que permitem o treinamento de redes extremamente profundas (centenas de camadas), evitando a perda de sinal.	Classificação de imagens de alta complexidade.
Transformer	Baseada inteiramente em mecanismos de atenção, dispensando a recorrência de RNNs. Consiste em pilhas de blocos de <i>Self-Attention</i> e <i>Feed-Forward</i> .	Grandes modelos de linguagem (ex: tradução e geração de texto).
U-Net	Arquitetura em formato de "U", com um caminho de contração para capturar contexto e um caminho de expansão para localização precisa.	Segmentação de imagens médicas (identificação de tumores em órgãos).

RELATÓRIO CONCLUSIVO

O estudo e a implementação de arquiteturas de Aprendizado Profundo demonstram a transição de algoritmos estáticos para modelos capazes de aprender, de maneira autônoma, abstrações complexas a partir de dados brutos.

Conclusões:

1. **Especialização:** Observa-se que não existe uma "arquitetura universal". Enquanto CNNs dominam o processamento espacial, arquiteturas baseadas em atenção (Transformers) revolucionaram o processamento sequencial.
2. **Eficiência vs. Complexidade:** O uso de técnicas como *Max Pooling* e o mecanismo de *Attention* mostra que o sucesso do Deep Learning não está apenas na profundidade da rede (número de camadas), mas na eficiência com que a informação relevante é filtrada e preservada.
3. **Impacto:** A convergência entre o poder de processamento (Hardware) e o refinamento destas arquiteturas permite hoje automatizar tarefas que antes exigiam intervenção humana constante, alterando drasticamente áreas como medicina, segurança e tecnologia da informação.

REFERÊNCIAS

IBM. **What is deep learning?** [2024]. Disponível em:

<https://www.ibm.com/think/topics/deep-learning>. Acesso em: 11 jun. 2026.

GEEKSFORGEEEKS. **Deep Learning Tutorial**. GeeksforGeeks, 2026a. Disponível em:

<https://www.geeksforgeeks.org/deep-learning/deep-learning-tutorial/>. Acesso em: 11 jun. 2026.

GEEKSFORGEEEKS. **Introduction to Convolution Neural Network**. GeeksforGeeks, 2026. Disponível em:

<https://www.geeksforgeeks.org/machine-learning/introduction-convolution-neural-network/>. Acesso em: 11 jun. 2026.

GEEKSFORGEEEKS. **Introduction to Pooling Layer in CNN**. GeeksforGeeks, 2026.

Disponível em:

<https://www.geeksforgeeks.org/deep-learning/introduction-to-pooling-layer-cnn/>. Acesso em: 11 jun. 2026.

GEEKSFORGEEEKS. **Implementing Recurrent Neural Networks in PyTorch**.

GeeksforGeeks, 2025. Disponível em:

<https://www.geeksforgeeks.org/deep-learning/implementing-recurrent-neural-networks-in-pytorch/>. Acesso em: 11 jun. 2026.

GEEKSFORGEEEKS. **Long short-term memory (LSTM) RNN in Tensorflow**.

GeeksforGeeks, 2025. Disponível em:

<https://www.geeksforgeeks.org/deep-learning/long-short-term-memory-lstm-rnn-in-tensorflow/>. Acesso em: 11 jun. 2026.

GEEKSFORGEEEKS. **Attention Mechanism in ML**. GeeksforGeeks, 2026. Disponível em:

<https://www.geeksforgeeks.org/artificial-intelligence/ml-attention-mechanism/>. Acesso em: 11 jun. 2026.

GEEKSFORGEEKS. **Understanding Recurrent Neural Networks (RNN)**. GeeksforGeeks, 2026. Disponível em: <https://www.geeksforgeeks.org/introduction-to-recurrent-neural-network/>. Acesso em: 16 jun. 2026.

GEEKSFORGEEKS. **Activation Functions in Neural Networks**. GeeksforGeeks, 2026. Disponível em: <https://www.geeksforgeeks.org/activation-functions-neural-networks/>. Acesso em: 16 jun. 2026.

GEEKSFORGEEKS. **Softmax Function in Machine Learning**. GeeksforGeeks, 2026. Disponível em: <https://www.geeksforgeeks.org/softmax-function-in-machine-learning/>. Acesso em: 16 jun. 2026.

GEEKSFORGEEKS. **Gradient Descent in Machine Learning**. GeeksforGeeks, 2026. Disponível em: <https://www.geeksforgeeks.org/gradient-descent-in-machine-learning/>. Acesso em: 16 jun. 2026.

GEEKSFORGEEKS. **Deep Learning Architectures: ResNet, U-Net, and Transformers**. GeeksforGeeks, 2026. Disponível em: <https://www.geeksforgeeks.org/deep-learning-architectures/>. Acesso em: 16 jun. 2026.

GOOGLE GEMINI. **Gemini: modelo de inteligência artificial generativa**. Assistente virtual para estruturação, revisão e formatação textual. Mountain View: Google, 2026. Disponível em: <https://gemini.google.com/>. Acesso em: 17 jun. 2026.