



CENTRO UNIVERSITÁRIO DE BRASÍLIA - CEUB
CIÊNCIA DA COMPUTAÇÃO

LUCAS GONÇALVES BALDUINO - 22409139

INTELIGÊNCIA ARTIFICIAL - II ATIVIDADE 1 APRENDIZADO NÃO SUPERVISIONADO

BRASÍLIA

2026

1 DEFINIÇÃO E CONCEITOS

O aprendizado não supervisionado é uma categoria de *Machine Learning* que utiliza algoritmos para processar e agrupar dados que não possuem rótulos prévios. Diferente do aprendizado supervisionado, o modelo identifica padrões ocultos e estruturas intrínsecas sem a necessidade de intervenção humana ou gabaritos de resposta. Este modelo subdivide-se em três tipos principais:

- **Agrupamento (Clustering):** Organiza os dados em grupos baseados em semelhanças. Pode ser exclusivo, sobreposto, hierárquico ou probabilístico.
- **Regras de Associação:** Identifica relações de dependência entre variáveis (ex: análise de cesta de compras).
- **Redução de Dimensionalidade:** Simplifica o volume de dados mantendo as informações essenciais.

2 ESTUDO DE CASO: AGRUPAMENTO EM GRID BIDIMENSIONAL

Considerando um conjunto de N pontos aleatórios em um plano cartesiano, o procedimento de agrupamento segue a seguinte metodologia:

a) Procedimento: Identificação de pontos vizinhos através do cálculo de proximidade métrica.

b) Metodologia de escolha: Utilização da **Distância Euclidiana** como métrica de similaridade. A definição dos grupos parte de centros iniciais, expandindo-se até que todos os pontos estejam vinculados a um agrupamento. A quantidade de grupos ideal busca respeitar a densidade natural dos dados, evitando generalizações excessivas.

c) Iteração e Parada: O algoritmo é iterativo. O critério de parada é definido pela estabilização dos grupos (convergência) ou pelo atingimento de uma quantidade mínima/máxima de grupos conforme o objetivo do projeto.

3 ALGORITMO K-MEANS

O K-means é um algoritmo de clustering exclusivo. O processo consiste em atribuir cada dado a um de K grupos. Cada grupo é representado por um **centróide**. O algoritmo busca minimizar a distância entre os pontos e seus respectivos centros através de um processo de refinamento contínuo.

4 IMPLEMENTAÇÃO EM PYTHON

Abaixo apresenta-se a implementação técnica utilizando as bibliotecas **NumPy** para processamento matemático e **Matplotlib** para visualização.

```

import numpy as np
import matplotlib.pyplot as plt

def kmeans(X, K, maxIteracoes=100):
    # 1. Inicialização: Escolhe K pontos aleatórios como centroides
    iniciais
    indices = np.random.choice(len(X), K, replace=False)
    centroides = X[indices]

    for i in range(maxIteracoes):
        # 2. Atribuição: Calcula distância Euclidiana e usa argmin
        # (Distância entre cada ponto e cada centroide)
        distancias = np.array([np.linalg.norm(X - c, axis=1) for c in
                                centroides])
        labels = np.argmin(distancias, axis=0)

        # Guardamos os centroides antigos para verificar a parada
        centroides_antigos = centroides.copy()

        # 3. Atualização: Move o centroide para a média do seu grupo
        for k in range(K):
            pontos_do_grupo = X[labels == k]
            if len(pontos_do_grupo) > 0:
                centroides[k] = pontos_do_grupo.mean(axis=0)

        # 4. Critério de Parada: Convergência
        if np.all(centroides_antigos == centroides):
            break
    return centroides, labels

# Exemplo de uso para o seu relatório:
N = 300
X = np.random.rand(N, 2) # N pontos aleatórios em 2D
K_ideal = 3 # Você pode testar diferentes valores

centros, grupos = kmeans(X, K_ideal)


# Visualização
plt.scatter(X[:, 0], X[:, 1], c=grupos, cmap='viridis', alpha=0.5)
plt.scatter(centros[:, 0], centros[:, 1], c='red', marker='x', s=200,
            label='Centroides')
plt.legend()
plt.show()

```

4.1 ANÁLISE DOS RESULTADOS

A implementação demonstra a eficácia do K-means em organizar dados aleatórios em sub estruturas espaciais. O uso da biblioteca NumPy permitiu a vetorização dos cálculos, aumentando a performance.

- **Cálculos:** A função `np.linalg.norm` aplica a norma L2, correspondente à distância linear no espaço euclidiano.
- **Análise Visual:** No gráfico gerado, observa-se que os centróides (marcados com 'X' vermelho) posicionam-se centralizadamente em relação às massas de dados coloridas, confirmando que a média aritmética foi calculada corretamente.
- **Conclusão:** O critério de parada por convergência garante que o algoritmo não execute ciclos desnecessários após encontrar a partição ótima para aquela inicialização específica.



REFERÊNCIAS

IBM. **O que é aprendizado não supervisionado?** Disponível em: <https://www.ibm.com/br-pt/think/topics/unsupervised-learning>. Acesso em: 14 mai. 2026.

GEMINI. **Assistente de Inteligência Artificial, Formatação.** Google, 2026.