



CENTRO UNIVERSITÁRIO DE BRASÍLIA - CEUB
CIÊNCIA DA COMPUTAÇÃO

LUCAS GONÇALVES BALDUINO - 22409139

INTELIGÊNCIA ARTIFICIAL- II LABORATÓRIO 1

BRASÍLIA

2026

RESUMO DO ARTIGO

O presente texto analisa o problema do treinamento de árvores de decisão utilizando bases de dados desbalanceadas, cenário no qual uma classe supera significativamente a outra em quantidade numérica. Este fenômeno ocorre porque, durante o processo de treinamento, as classes majoritárias são favorecidas, tornando o algoritmo enviesado e negligente em relação à classe minoritária. Para mitigar esse viés, utilizam-se métodos para tratar a base de dados e estruturar o treinamento, destacando-se três abordagens principais: a reamostragem, que altera a base de dados aumentando a classe minoritária por duplicação ou dados artificiais (SMOTE) ou diminuindo a classe majoritária; o aprendizado sensível à penalidade, que pune severamente o algoritmo ao errar a classificação da classe minoritária; e o emprego de métricas de avaliação alternativas, que priorizam a análise de erros críticos como os falsos-negativos.

IMPLEMENTAÇÃO

Implementação anexada em formato de arquivo .ipynb (Jupyter) do GEEKSFORGEES implementando o método SMOTE e suas variantes. O método SMOTE é uma grande ferramenta para o tratamento de dados balanceados, porém ele não possui um desempenho muito bom para bases de dados muito grandes e diferentes tipos de bases de dados, dessa forma foram desenvolvidas outras variantes desse método:

SMOTE (Original): Seleciona um ponto aleatório da classe minoritária e seleciona seus k vizinhos mais próximos da mesma classe e cria novos pontos com base nos pontos originais selecionados.

ADASYN (Adaptativo): Identifica as maiores dificuldades de classificação entre a classe minoritária ou majoritária e a partir disso, criando mais dados sintéticos na região em que a classificação tem mais dificuldade, aumentando gradualmente a partir de dados com menos dificuldade até dados com maior dificuldade.

Boderline-SMOTE: Classifica os pontos da classe minoritária categorias com base na quantidade de classes majoritárias ao redor deles, e a partir disso atribui a geração de dados sintéticos apenas em região de barreira entre duas classes, onde a classificação é mais complicada.

SMOTE-ENN: Combina duas técnicas na preparação da base de dados, aplica o SMOTE para a geração de dados sintéticos e, em seguida, aplica o ENN para limpar a base de dados de ruídos e pontos de classificação errada das duas classes, tornando a base mais limpa e viável.

SMOTE-TOMEK: Combina duas técnicas de preparação da base de dados, aplica o SMOTE para a geração de dados sintéticos e, em seguida, aplica o Tomek Link para eliminar pares de classes opostas na borda de classes que atrapalham na classificação dessas classes.

SMOTE-NC (Nominal Continuous): É uma forma de lidar com bases de dados que possuem tanto dados numéricos quanto dados categóricos tratando esses tipos de dados de formas diferentes na etapa da geração de dados sintéticos.

Em suma, existem diferentes variantes do método SMOTE, que dependendo das características da base de dados, são mais adequadas para o tratamento, utilizando diferentes modos de manipular os dados para preparar para o treinamento, seja por aumentando a quantidade de pontos da classe minoritária ou métodos híbridos.

REFERÊNCIAS

GEEKSFORGEEKS. **How do decision trees work with unbalanced datasets?** [S. l.], 23 jul. 2025. Disponível em: <https://www.geeksforgeeks.org/machine-learning/how-do-decision-trees-work-with-unbalanced-datasets/>. Acesso em: 21 maio 2026.

GEEKSFORGEEKS. **SMOTE for Imbalanced Classification with Python.** [S. l.], 10 fev. 2026. Disponível em: <https://www.geeksforgeeks.org/machine-learning/smote-for-imbalanced-classification-with-python/>. Acesso em: 21 maio 2026.

GOOGLE. **Gemini.** Versão de maio de 2026. Mountain View: Google, 2026. Inteligência artificial generativa utilizada no suporte à formatação textual e normalização documental segundo os padrões da ABNT.