



CENTRO UNIVERSITÁRIO DE BRASÍLIA - CEUB
CIÊNCIA DA COMPUTAÇÃO

LUCAS GONÇALVES BALDUINO - 22409139

INTELIGÊNCIA ARTIFICIAL- II LABORATÓRIO 2

BRASÍLIA

2026

1. K-MEANS

1.1 Explicação e funcionamento do algoritmo

O K-means é um algoritmo de clustering exclusivo. O processo consiste em atribuir cada dado a um de K grupos. Cada grupo é representado por um centróide. O algoritmo busca minimizar a distância entre os pontos e seus respectivos centros através de um processo de refinamento contínuo atribuindo um novo centróide e atualizando com um novo cálculo de média.

1.2 Reprodução dos resultados

Arquivo de python anexado. O Script demonstra as etapas do algoritmo K-means no processo de agrupamento de dados, utilizando uma nuvem de pontos como base, adicionando os centróides iniciais e as adaptações para chegar ao centro dos grupamentos.

1.3 Discussão dos resultados e modificação das condições iniciais

Alterando a seed randômica para 13 por exemplo, gera grupamentos que não refletem exatamente os grupos naturais da nuvem de pontos, dividindo alguns grupos e ampliando outros, ou seja, a posição inicial dos centróides implica bastante nos grupamentos finais, não necessariamente agrupando da forma correta.

1.4 Sumário final

O algoritmo K-means mostrou-se uma ferramenta eficiente e de fácil implementação para o agrupamento de dados bem espaçados e de formato esférico. Contudo, os testes práticos comprovaram que sua eficácia é altamente dependente da escolha inicial da posição dos centróides (sensibilidade à semente aleatória), o que pode levar a agrupamentos incorretos ou pouco representativos da realidade dos dados. Portanto, conclui-se que, para mitigar esse problema em cenários reais, técnicas de inicialização avançadas ou múltiplas execuções com diferentes sementes são fundamentais para garantir a estabilidade e a qualidade do agrupamento final.

2. DBSCAN

2.1 Implementação do algoritmo DBSCAN Arquivo em python anexado.

2.2 Comparação dos resultados entre K-means e DBSCAN

O DBSCAN é um algoritmo de agrupamento baseado na densidade de pontos de uma base, esse tipo de algoritmo possui um melhor desempenho em agrupamentos que um algoritmo como o K-means pois quando ele se baseia na densidade de pontos, independente do formato dos agrupamentos, o DBSCAN consegue agrupá-los com o uso do Epsilon que define o raio dos grupos e o Valor mínimo de pontos dentro desse raio, identificando pontos centrais, pontos de borda e outliers e ruídos, e de maneira adequada e que em agrupamentos de formatos não arbitrários e que não se parecem com círculos, o K-means perde desempenho, além de ser sensível a ruídos e outliers, que conseguem ser identificados pelo DBSCAN.

3. PCA

3.1 Explicação de como o algoritmo funciona

O PCA é uma técnica de redução de dimensões de bases de dados contendo informações principais, removendo redundâncias, aumentando a eficiência computacional e tornando a visualização e processamento de dados mais simples. Ele realiza essa redução projetando os dados originais em eixos ortogonais e utilizando a variância para determinar a importância dos dados que serão mantidos na redução.

3.2 Implementação do PCA Arquivo em python anexado.

REFERÊNCIAS BIBLIOGRÁFICAS

GEEKSFORGEEKS. **DBSCAN Clustering in ML | Density-based Clustering**. GeeksforGeeks, 2024. Disponível em: <https://www.geeksforgeeks.org/machine-learning/dbscan-clustering-in-ml-density-based-clustering/>. Acesso em: 28 mai. 2026.

GEEKSFORGEEKS. **K-Means Clustering Introduction**. GeeksforGeeks, 2024. Disponível em: <https://www.geeksforgeeks.org/machine-learning/k-means-clustering-introduction/>. Acesso em: 28 mai. 2026.

GEEKSFORGEEKS. **Principal Component Analysis (PCA)**. GeeksforGeeks, 2024. Disponível em: <https://www.geeksforgeeks.org/data-analysis/principal-component-analysis-pca/>. Acesso em: 28 mai. 2026.

GOOGLE. **Gemini (Versão de maio de 2026)**. Mountain View: Google, 2026. Inteligência artificial generativa utilizada no suporte à formatação textual e normalização documental segundo os padrões da ABNT.